

学校代码: 10284  
分类号: TP391.1  
密 级: 公开  
U D C:  
学 号: DZ20330002



南京大學

# 博 士 学 位 论 文

|         |                      |
|---------|----------------------|
| 论 文 题 目 | 时态知识图谱的构建与<br>应用技术研究 |
| 作 者 姓 名 | 陈剑豪                  |
| 专 业 名 称 | 计算机科学与技术             |
| 研 究 方 向 | 知识图谱                 |
| 导 师 姓 名 | 瞿裕忠 教授 胡伟 教授         |

2025 年 12 月 20 日

|         |       |
|---------|-------|
| 答辩委员会主席 | 漆桂林教授 |
| 评阅人     | 陈华钧教授 |
|         | 王利民教授 |
|         | 黄书剑教授 |
|         | 程龚教授  |

论文答辩日期      2026 年 2 月 2 日

研究生签名:

导师签名:

# **Research on the Construction and Application Technologies of Temporal Knowledge Graphs**

by  
**Jianhao Chen**

Supervised by  
Professor Yuzhong Qu  
Professor Wei Hu

A dissertation submitted to  
the graduate school of Nanjing University  
in partial fulfilment of the requirements for the degree of

DOCTOR OF PHILOSOPHY

in  
Computer Science and Technology



School of Computer Science  
Nanjing University

December 20, 2025



# 南京大学研究生毕业论文中文摘要首页用纸

毕业论文题目：时态知识图谱的构建与应用技术研究

计算机科学与技术 专业 2020 级博士生姓名：陈剑豪

指导教师（姓名、职称）：瞿裕忠 教授 胡伟 教授

## 摘 要

随着人工智能技术的发展，如何让机器理解动态变化的现实世界，并基于此进行复杂的逻辑推理与任务规划，已成为当前学术界与工业界重点关注的命题。传统的静态知识图谱虽然在组织结构化知识方面取得了巨大成功，但其忽视了知识随时间演化的本质特征，导致了时间理解鸿沟的出现。时态知识图谱通过引入时间维度，精确刻画了实体状态的演化轨迹，成为了连接静态数据与动态世界的关键桥梁。然而，现有的时态知识图谱技术体系在从非结构化数据中获取复杂时态信息、在大规模图谱上保障逻辑一致性，以及在动态环境下利用时态知识进行鲁棒规划等方面，仍面临着严峻的科学挑战。

针对上述问题，本文围绕“时态知识图谱的构建与应用”这一主线展开系统性研究。其中，构建技术涵盖了时态事实抽取与数据质量控制两个关键环节。本文旨在建立一套从源头数据治理到上层智能决策的系统性技术栈，重点攻克了复杂语境下的时态解析、大规模时序逻辑校验效率瓶颈以及概率生成模型在硬性约束下的规划幻觉等关键难题。主要创新成果概括如下：

第一，提出基于时间线分解的复杂时态事实抽取技术。针对非结构化文本中时序交错与隐式表达难以解构的痛点，创新性地利用大语言模型实现基于时间线的句子分解策略，将复杂嵌套句解构为锚定时间点的原子事件，消除了句法歧义。在此基础上，构建了 TSDRE (Timeline-based Sentence Decomposition Relation Extraction) 技术，采用知识蒸馏的思路，将大模型生成的高质量分解知识融入到较小预训练语言模型的微调过程中。这一范式不仅保留了小模型在指令遵循上的优势，还赋予了其处理复杂时态逻辑的能力。实验结果表明，该技术在处理多重嵌套和长距离依赖的时态文本时，性能显著优于现有的端到端抽取模型。

第二，构建基于结构模式的自动化时序约束挖掘与时态事实冲突检测方法。

针对冲突检测依赖人工规则且效率低下的瓶颈，提出将时序约束形式化为“结构模式 + 时序谓词”的自动化挖掘方法 PaTeCon (Pattern-based Constraint Mining)，并设计了基于类别信息的自动细化机制以降低误报。为应对千万级规模的知识图谱的挖掘开销，进一步提出了效率增强版挖掘方法 PaTeCon+，引入实体级置信度度量及基于大数定律的两阶段剪枝策略，大幅提升了挖掘效率。实验证明，该方法不仅能高效发现高质量的细粒度约束，还能作为过滤器显著提升时态知识图谱补全模型的预测质量，实现了数据质量的自动化治理。

第三，设计基于时间感知事件搜索的多约束规划智能体框架。针对大模型智能体在动态环境下长程规划易产生幻觉与违规的问题，提出神经符号协同规划框架 TAES (Time-aware Event Search)。该框架将时态知识图谱作为底层环境模型，通过事件驱动的状态跳跃机制将连续时间离散化，有效压缩了搜索空间。决策上融合了大模型的生成直觉与基于代码逻辑的符号化硬约束剪枝，并引入前瞻性启发式评估函数规避规划陷阱。实验表明，该方法在旅行计划和事件规划基准上实现了 99% 的硬约束满足率，并且在最终任务成功率上显著优于现有的智能体框架。

综上所述，本文系统性地探索了时态知识图谱构建与应用的关键技术，构建了一套逻辑严密、相互支撑的技术体系。这些成果不仅丰富了时态知识图谱的理论与方法，也为构建智能、可信、鲁棒的时间感知人工智能系统提供了坚实支撑。

**关键词：**时态知识图谱；信息抽取；约束挖掘；冲突检测；智能体规划；神经符号协同

## 南京大学研究生毕业论文英文摘要首页用纸

THESIS: Research on the Construction and Application Technologies of Temporal Knowledge Graphs

SPECIALIZATION: Computer Science and Technology

POSTGRADUATE: Jianhao Chen

MENTOR: Professor Yuzhong Qu Professor Wei Hu

### ABSTRACT

With the rapid advancement of artificial intelligence, enabling machines to understand the dynamically changing real world and perform complex logical reasoning and task planning has become a pivotal focus in both academia and industry. While traditional static knowledge graphs have achieved great success in organizing structured knowledge, they often overlook the evolutionary nature of knowledge over time, leading to a significant temporal understanding gap. By introducing the temporal dimension, Temporal Knowledge Graphs (TKGs) accurately characterize the evolution of entity states, serving as a crucial bridge between static data and the dynamic world. However, existing TKG technologies still face severe scientific challenges in terms of acquiring complex temporal information from unstructured data, ensuring logical consistency within large-scale graphs, and performing robust planning using temporal knowledge in dynamic environments.

To address these issues, this dissertation conducts a systematic study centered on the core theme of “Construction and Application of Temporal Knowledge Graphs.” Within this framework, the construction technology encompasses two critical stages: temporal fact extraction and data quality control. The research aims to establish a systematic technical stack—ranging from source data governance to high-level intelligent decision-making—with a specific focus on overcoming key challenges such as temporal parsing in complex contexts, efficiency bottlenecks in large-scale temporal logic validation, and planning hallucinations of probabilistic generative models under hard constraints. The main innovations are summarized as follows:

First, a complex temporal fact extraction technique based on timeline decomposition is proposed. Addressing the pain point that interleaved temporal sequences and implicit expressions in unstructured text are difficult to deconstruct, a timeline-based sentence decomposition strategy is innovatively implemented using large language models, deconstructing complex nested sentences into atomic events anchored to time points, which eliminates syntactic ambiguity. On this basis, the TSDRE (Timeline-based Sentence Decomposition Relation Extraction) framework is constructed, adopting the idea of knowledge distillation to integrate high-quality decomposition knowledge generated by large models into the fine-tuning process of smaller pre-trained language models. This paradigm not only retains the advantages of small models in instruction following, but also endows them with the capability to process complex temporal logic. Experimental results demonstrate that this technique significantly outperforms existing end-to-end extraction models when handling temporal texts involving multiple nesting and long-distance dependencies.

Second, an automated temporal constraint mining and temporal conflict detection method based on structural patterns is constructed. Addressing the bottleneck where conflict detection relies on manual rules and is inefficient, an automated mining method PaTeCon (Pattern-based Constraint Mining) is proposed, which formalizes temporal constraints as a logical combination of “structural patterns + temporal predicates”, and an automated refinement mechanism based on category information is designed to reduce false positives. To cope with the mining overhead of tens-of-millions-scale knowledge graphs, an efficiency-enhanced mining method PaTeCon+ is further proposed, introducing entity-level confidence metrics and a two-stage pruning strategy based on the Law of Large Numbers, which significantly improves mining efficiency. Experiments prove that this method can not only efficiently discover high-quality fine-grained constraints, but also serve as a filter to significantly improve the prediction quality of temporal knowledge graph completion models, achieving automated governance of data quality.

Third, a time-aware event search-based multi-constraint planning agent framework is designed. Addressing the pain point where large language model agents are prone to



hallucinations and violations during long-range planning in dynamic environments, a neuro-symbolic collaborative planning framework TAES (Time-aware Event Search) is proposed. This framework treats the temporal knowledge graph as the underlying environment model and discretizes continuous time into key decision points through an event-driven state jump mechanism, effectively compressing the search space. In the decision-making mechanism, it integrates the generative intuition of large language models with symbolic hard constraint pruning based on code logic, and introduces a forward-looking heuristic evaluation function to avoid planning traps. Experimental results show that this method achieves a 99% hard constraint satisfaction rate on travel planning and event planning benchmarks, and significantly outperforms existing agent frameworks in terms of the final task success rate.

In summary, this dissertation systematically explores the key technologies across the entire life cycle of temporal knowledge graphs, constructing a logically rigorous and mutually supportive technical system. These achievements not only enrich the theories and methods of temporal knowledge graphs but also provide solid technical support for building intelligent, trustworthy, and robust time-aware artificial intelligence systems.

**KEYWORDS:** Temporal Knowledge Graph; Information Extraction; Constraint Mining; Conflict Detection; Agent Planning; Neuro-Symbolic Synergy



# 目 录

|                       |     |
|-----------------------|-----|
| 目 录                   | VII |
| 插图目录                  | IX  |
| 表格目录                  | XI  |
| 第一章 基于时态知识图谱的多约束规划智能体 | 1   |
| 1.1 研究背景与问题           | 1   |
| 1.2 时间感知事件搜索框架        | 5   |
| 1.2.1 统一的时间感知事件空间     | 5   |
| 1.2.2 神经符号协同的集束搜索框架   | 6   |
| 1.2.3 多级状态评估机制        | 9   |
| 1.3 性能评估              | 11  |
| 1.3.1 实验设置            | 11  |
| 1.3.2 主要结果            | 14  |
| 1.3.3 消融实验            | 16  |
| 1.3.4 错误分析            | 18  |
| 1.3.5 案例研究            | 19  |
| 1.4 本章小结              | 20  |
| 参考文献                  | 21  |
| 攻读博士学位期间研究成果          | 23  |



## 插图目录

|     |                                                                                                                                                                         |   |
|-----|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---|
| 1-1 | TravelPlanner 任务示例 . . . . .                                                                                                                                            | 2 |
| 1-2 | TimeArena 任务示例 . . . . .                                                                                                                                                | 3 |
| 1-3 | 时间感知事件搜索 (TAES) 框架展示。神经符号集束搜索按事件驱动的<br>深度进行树搜索算法。大语言模型生成器基于时态知识图谱上下文提出<br>动作，并进行状态跃迁。两阶段评估首先应用符号硬剪枝以确保无违<br>约计划，随后进行启发式评估打分。仅选择前 B 个状态进入下一轮迭<br>代，直至迭代完成返回最优计划。 . . . . | 5 |



## 表格目录

|     |                                          |    |
|-----|------------------------------------------|----|
| 1-1 | TravelPlanner 数据集上不同模型和方法的性能对比 . . . . . | 15 |
| 1-2 | TimeArena 数据集上不同模型和方法的性能表现 . . . . .     | 16 |
| 1-3 | TravelPlanner 上的消融实验 . . . . .           | 17 |
| 1-4 | TimeArena 数据集上的消融实验 . . . . .            | 17 |





# 第一章 基于时态知识图谱的多约束规划智能体

## 1.1 研究背景与问题

本文在前两章中已经介绍了时态知识图谱的构建及质控关键技术，完成高质量的知识图谱构建只是第一步，更重要的是如何发挥知识图谱结构化、高可信度的优势，创造出实用便捷的人工智能应用。本章在前文时态知识谱图构建的基础上，将整个研究向实用性方向推进，探索时态知识图谱作为智能体交互环境的情况下，在现实世界中的具体应用如旅行规划，事件统筹安排等。

在人工智能的现有发展阶段，大语言模型已在文本理解、代码生成及基础工具调用方面展现了令人瞩目的能力。然而，随着应用场景从静态的问答系统向复杂的现实世界任务迁移，智能体所处的环境呈现出高度的动态性与时序性<sup>[1]</sup>。在物流调度、跨国旅行规划、精细化工业控制乃至个人日程管理等领域，智能体不再仅仅是信息的检索者，更需要成为具备时间感知能力的规划者。在这些复杂的任务场景中，时态知识图谱扮演着核心环境的角色。不同于传统的静态知识库，时态知识图谱通过时间戳和持续时间精确刻画了实体状态随时间的演化轨迹——例如航班的起降时刻表、酒店的季节性价格波动、烹饪步骤的先后依赖关系等。对于规划智能体而言，时态知识图谱构成了其认知的物理边界与规则底座<sup>[2]</sup>：时态知识图谱中海量的知识节点，构成了智能体规划过程中可遍历的、明确的事件状态空间；知识间的时序约束则显式地刻画了事件间的依赖。一个合格的时间感知智能体，必须具备在时态知识图谱构建的四维时空（三维空间 + 一维时间）中进行导航的能力，即在满足资源独占、时序依赖及截止日期等严格约束的前提下，统筹规划出一条最优的行动轨迹。

此类时间感知智能体具有极高的应用价值。它不仅能够作为个人助理处理长程且复杂的调度任务，如规划一场横跨欧洲三国、为期两周且预算有限的商务考察，还能在企业级应用中优化资源配置效率。这要求智能体超越简单的语义理解，具备精确的时间观念和全局统筹能力，像人类专家一样，在多重约束下寻找

最优解，并能预判当前决策对未来状态的长远影响。




图 1-1 TravelPlanner 任务示例  
(图片引用自文献<sup>[3]</sup>)

尽管愿景美好，但现有的基于大语言模型的智能体在处理此类长程规划任务时，面临着严峻的挑战。以 TravelPlanner<sup>[3]</sup>和 TimeArena<sup>[4]</sup>为代表的基准测试，本质上是基于时态知识图谱环境的复杂规划问题，成为了检验智能体能力的试金场。在这些任务中，智能体并非简单地按顺序执行指令，而是需要进行全局统筹与动态调整，在多重约束下权衡每一步的利弊并最终完成任务。

具体而言，时间感知规划任务目前面临三大核心挑战，这些挑战揭示了概率生成模型与确定性约束求解之间的本质矛盾：

第一大挑战是规划任务中的长程依赖。现实世界的规划往往涉及多重硬性条件的交织，形成了一个复杂的依赖网络，导致搜索空间出现组合爆炸。以图1-1中一个具体的 TravelPlanner 场景为例：用户要求“规划单人 5 天的行程，总预算不超过 6000 美元，必须订宠物友好房间”。这是一个典型的多因素耦合场景：为了从西雅图前往加利福尼亚，智能体倾向于选择飞机作为出行方式，进而压缩了剩余预算。同时，携带宠物这一约束又极大地缩减了住宿的可选范围，往往迫使智能体选择价格昂贵的高端宠物友好酒店。接下来规划每日行程保持预算和出行体验的平衡就成为了一大难题。在长达 5 天的规划中，第 1 天的一个微小决策例如选择了一家昂贵的餐厅可能产生蝴蝶效应，耗尽后续日期的预算资源，导致第 5 天无法支付返程路费。现有的自回归模型难以建模这种跨越数十个决

策步的长程依赖，往往陷入局部最优而忽视全局可行性。

第二大挑战是动态环境中的纠错能力缺失。如图1-2所示，在 TimeArena 这类模拟厨房或实验室流程的任务中，动作之间存在严格的物理依赖，如必须先洗杯子才能往杯子中倒茶。现有的智能体在生成计划时，常常表现出工具调用错误的累积与僵化，当一个子任务失败时如直接往杯子中倒茶，它们往往无法进行局部的回溯修正，而是导致整个计划的崩塌。




图 1-2 TimeArena 任务示例

(图片引用自文献<sup>[4]</sup>)

第三大挑战是隐性常识与显性规则的约束。合理规划需调用大量人类常识，如“避免同日重复去同一家餐厅”、“跨城交通需预留接驳时间”、“自驾车辆不能在异地遗弃”。然而，大语言模型难以将这些隐性规则转化为严格的显性约束。实验数据显示，在常识性约束方面，即便是最先进模型 DeepSeek-R1<sup>[5]</sup>，o3-mini 也存在高达 20% 的幻觉率，这意味着模型经常产生违反常识的不可行计划。

面对上述挑战，先前工作提出了多种解决方案，但仍存在本质局限。CoT<sup>[6]</sup>，ReAct<sup>[7]</sup>等单智能体方法主要依赖大语言模型的直觉，即通过概率生成的文本来逼近解决方案。这种方法缺乏底层的符号化验证机制，极易在硬约束上产生幻觉，且无法有效处理长程依赖<sup>[8]</sup>。PMC<sup>[9]</sup>，LRPLAN<sup>[10]</sup>等多智能体协作方法引入了分工机制，试图通过“经理-执行者”或“规划者-精炼者”的架构来分而治之。然而，PMC 严重依赖于最后阶段的交付者进行全局汇总，一旦预算在最后一步超支，缺乏有效的回溯机制；LRPLAN 虽然引入了推理大模型进行修正，但其本质仍是基于概率的生成与反思，缺乏对 TKG 环境状态的精确追踪。正如研究指

出，这些方法在面对严格的物理边界如 TravelPlanner 中的资源锁定时，仍无法保证零违约。

上述问题的核心问题在于：自回归概率生成的范式与复杂规划的精确求解本质不匹配。为了解决上述问题，本章提出了一种基于时间感知事件搜索（Time-Aware Event Search, TAES）的多约束规划框架。其核心洞察在于，复杂的规划问题不应被视为一个线性的文本生成任务，而应被建模为在时态知识图谱环境中的神经符号搜索过程。具体而言，TAES 将时态知识图谱中的时态信息转化为搜索树上的离散事件节点，并设计了一种新颖的协作机制：利用大语言模型发挥其生成丰富候选动作的直觉优势，同时引入基于硬逻辑的启发式状态评估器进行符号剪枝。通过这种方式，TAES 在搜索过程中即时阻断任何违反时态依赖或资源约束的路径，并利用前瞻性启发函数引导智能体向预算健康、时间高效的方向探索。

在两个数据集上的实验表明，相比现有方法，TAES 显著提升了显性约束和常识约束的满足率，并且在最终任务完成率上达到了 SOTA 效果。此外，TAES 也并未大幅增加计算开销，相比现有方法，TAES 在取得高性能的同时开销仍低于绝大部分方法。

本章的主要贡献总结如下：

1. 本章将时间感知规划问题形式化为基于事件的树搜索问题，提出了一个统一的框架 TAES。通过状态跳跃机制，将搜索深度从物理时间长度压缩为关键决策次数，从而能够高效处理长程规划。
2. TAES 结合了大语言模型的常识生成能力与硬性约束的规则检查。这一机制极大保证了生成计划的低违约，大幅缓解了现有方法在硬约束下脆弱的问题。
3. 在 TravelPlanner 和 TimeArena 两个具有挑战性的数据集上的实验表明，TAES 方法在硬约束满足率上达到了 99% 的水平，并在最终规划成功率上显著优于 PMC、LRPLAN 等基线方法，验证了结构化搜索与验证机制是提升大模型智能体鲁棒性的关键路径。




图 1-3 时间感知事件搜索（TAES）框架展示。神经符号集束搜索按事件驱动的深度进行树搜索算法。大语言模型生成器基于时态知识图谱上下文提出动作，并进行状态跃迁。两阶段评估首先应用符号硬剪枝以确保无违约计划，随后进行启发式评估打分。仅选择前  $B$  个状态进入下一轮迭代，直至迭代完成返回最优计划。

## 1.2 时间感知事件搜索框架

本章将多约束下的复杂规划问题形式化为一个在时态环境中的决策过程。为了解决现有方法在长程依赖和硬性约束上的脆弱性，本章提出了 TAES 框架。如图 1-3 所示，该框架采用了“神经生成-符号验证”的协作范式，由三个核心模块构成：基于时态事件的统一状态空间建模、神经符号协同的集束搜索架构，以及层级化的多级状态评估机制。

### 1.2.1 统一的时间感知事件空间

不同于基于固定时间步长的线性规划方法，TAES 将规划过程建模为在离散事件图上的导航。这种建模方式能够统一抽象粗粒度的日程规划和细粒度的动作调度，如统一抽象 TravelPlanner 中的单日行程与 TimeArena 中的原子动作为原子事件，而非类似 TimeArena 中固定时间刻度每分钟，有效避免了搜索空间随物理时间跨度呈指数级爆炸的问题。

#### 1.2.1.1 事件驱动的状态定义

TAES 将智能体在时刻  $t$  的规划状态形式化为三元组  $S_t = (\mathcal{T}_{now}, \mathcal{R}, C_{met})$ ，其中：

- $\mathcal{T}_{now} \in \mathbb{R}_{\geq 0}$  表示当前的全局时间指针。
- $\mathcal{R}$  表示当前的资源快照。在 TravelPlanner 中， $\mathcal{R}$  包含剩余预算及交通工具状态；在 TimeArena 中， $\mathcal{R}$  包含空闲的厨具、实验设备或人员状态。
- $\mathcal{C}_{met} \subseteq \mathcal{C}_{goal}$  表示当前已满足的子目标或约束集合，例如已完成的烹饪子任务、已预订的住宿。

TAES 定义事件  $E$  为搜索树上的基本转移单元。事件不仅包含动作本身如“chop\_tomato”，还隐含了该动作所需的持续时间  $\Delta t_E$  和资源需求。

### 1.2.1.2 基于事件的时间跳跃机制

不同于传统规划模型采用等时步长的离散化方式，TAES 引入了非均匀时间步机制，即状态转移函数  $\Phi(S_t, E) \rightarrow S_{t+1}$ 。该函数包含两个关键逻辑步骤：

**动作执行与资源锁定** 在当前时间  $\mathcal{T}_{now}$  尝试执行事件  $E$ 。系统根据时态知识图谱中的定义，锁定相关资源并更新  $\mathcal{C}_{met}$ 。在物理时间跳跃的区间内，被占用的资源，如切菜的厨师、已参观的景点在状态  $\mathcal{R}$  中被标记为锁定，当厨师在接下来的 5 分钟内切菜时，系统可以并行评估其他不依赖该厨师的动作分支，当系统规划下一天的旅游行程，可以排除已经参观的景点。

**时间快进** 这是 TAES 区别于传统规划器的核心机制。如果执行  $E$  后系统进入资源等待状态，例如厨师正在切菜，耗时 3 分钟，系统自动将  $\mathcal{T}_{now}$  快进到下一个决策点。决策点定义为“任一占用型资源被释放”或“任一前置依赖被满足”的时刻：

$$\mathcal{T}_{next} = \min\{\text{end\_time}(\tau) \mid \tau \in \text{RunningTasks}\} \quad (1-1)$$

这种机制将搜索树的深度  $D$  从物理时间长度  $O(T)$  压缩为关键决策次数  $O(N_{actions})$ ，使得长程规划在计算上变得可行且高效。

### 1.2.2 神经符号协同的集束搜索框架

为了结合大语言模型的生成直觉与符号系统的逻辑严谨性，本章设计了基于集束搜索的协同框架。该框架维护一个宽度为  $B$  的集束  $\mathcal{B}_d$ ，包含当前时刻最优的  $B$  个部分计划。



### 1.2.2.1 神经生成器

TAES 将大语言模型视为系统的思考引擎  $F_\theta$ 。在搜索树的每一步扩展中, LLM 接收当前状态描述  $S_t$  和来源于 TKG 的环境上下文  $C_{tkg}$ , 并生成  $k$  个候选动作集合:

$$\mathcal{A}_{cand} = \{E_1, E_2, \dots, E_k\} \sim F_\theta(S_t, C_{tkg}) \quad (1-2)$$

在此过程中, LLM 的作用仅限于利用其常识推理能力来提供高质量的候选集, 如“先切菜再炒菜”、“去巴黎应该参观铁塔”, 从而大幅缩减搜索的分支因子。其本质是一种利用大模型生成的启发式搜索算法, 从而避免现实世界组合爆炸的问题。

### 1.2.2.2 搜索与剪枝流程

算法的核心是一个迭代的“扩展-评估-筛选”闭环, 具体伪代码如算法1所示。其主要流程如下:

1. **扩展:** 对集束  $B_d$  中的每个父状态, 调用神经生成器生成  $k$  个子状态, 总计产生  $B \times k$  个候选路径。大语言模型在此充当直觉驱动搜索分支引导器, 它基于当前状态  $S_t$  的描述, 例如“已规划至第 3 天, 剩余预算 \$1200”及从时态知识图谱检索的上下文如附近的酒店信息, 提出最具合理性的候选动作。这一步极大压缩了暴力搜索的分支, 将可能的动作空间缩减为人类常识认为合理的动作子集。
2. **符号化评估:** 调用评估函数  $V(S)$  对所有候选路径进行打分与剪枝。 $V(S)$  包括两部分: 通过代码逻辑强制阻断任何违反硬性约束的分支; 通过启发式打分机制将风险较低的方案排序在候选的前列。
3. **筛选:** 根据分数对候选状态排序, 保留前  $B$  个最优状态进入下一轮  $B_{d+1}$ 。这允许系统保持多条潜在的可行路径, 当某条路径在未来遭遇死胡同时, 其他分支能够提供有效的回溯空间。

**Algorithm 1** 神经符号协同的集束搜索算法

**Require:** User Query  $Q$ , TKG  $\mathcal{G}$ , Beam Width  $B$ , Branching Factor  $K$ , Max Depth  $D_{\max}$

**Ensure:** Optimal Plan  $S^*$  or Failure  $\perp$

```

1: Initialize beam  $B_0 \leftarrow \{S_{\text{init}}\}$  where  $S_{\text{init}} = (\mathcal{T}_0, \mathcal{R}_{\text{init}}, \emptyset)$ 
2: for  $d = 0$  to  $D_{\max}$  do
3:    $C_{\text{candidate}} \leftarrow \emptyset$  {Initialize candidate set for next depth}
4:   // Phase 1: 大模型生成
5:   for all  $S \in B_d$  do
6:     if  $\text{IS\_TERMINAL}(S)$  then
7:       Add  $S$  to  $C_{\text{candidate}}$ 
8:     continue
9:   end if
10:  Context  $\leftarrow \text{RETRIEVE\_CONTEXT}(S, \mathcal{G})$ 
11:   $\mathcal{A} \leftarrow \text{LLM\_GENERATE}(S, \text{Context}, K)$ 
12:  for all action  $a \in \mathcal{A}$  do
13:    // Phase 2: 事件驱动状态转移
14:     $S_{\text{new}} \leftarrow \text{EXECUTE\_ACTION}(S, a)$ 
15:     $S_{\text{next}} \leftarrow \text{TIMEFORWARD}(S_{\text{new}})$  {Jump to next decision point}
16:    // Phase 3: 基于符号剪枝
17:    if  $\text{SYMBOLICCHECK}(S_{\text{next}}, \Omega_{\text{hard}})$  is True then
18:      // Phase 4: 启发式评价
19:      Score  $\leftarrow \text{EVALUATE}(S_{\text{next}}, V_{\text{soft}})$ 
20:      Add  $(S_{\text{next}}, \text{Score})$  to  $C_{\text{candidate}}$ 
21:    end if
22:  end for
23: end for
24: // Phase 5: 筛选
25: if  $C_{\text{candidate}} == \emptyset$  then
26:   return  $\perp$  {Search space exhausted (Dead end)}
27: end if
28: Sort  $C_{\text{candidate}}$  by Score descending
29:  $B_{d+1} \leftarrow \text{TOP-B}(C_{\text{candidate}})$ 
30: if All states in  $B_{d+1}$  are terminal then
31:   break
32: end if
33: end for
34: return  $S^* \in B_{\text{last}}$  with maximum Score

```

## 1.2.2.3 决策过程的马尔科夫属性

在 TAES 框架中, 规划过程可以形式化为一个离散的时间感知马尔可夫决策过程。为了确保搜索算法的理论严谨性, 状态  $S_t$  的定义遵循完备性原则。具体而言, 虽然规划任务本质上具有长程时序特征, 但通过将历史关键决策信息记录在智能体记忆中。例如, 在 TravelPlanner 场景下, 用户往往要求“避免景点/餐



馆重复”。若系统仅记录前一天的行程，则必须回溯历史轨迹查看历史行程，这会显著增加搜索复杂度。为此，在  $C_{met}$  中维护一个动态更新的已访问属性集合。当智能体在  $T_1$  时刻选择了一家法式餐厅，该属性即被固化在  $S_{T_1}$  的  $C_{met}$  中。在后续  $T_n$  时刻的决策中，神经生成器仅需检索当前  $S_t$  即可识别约束冲突，而无需重新扫描  $T_1$  到  $T_{n-1}$  的所有已生成的计划文本。这种处理方式将复杂的长程依赖转化为状态空间内的即时约束校验，使得搜索过程满足马尔可夫属性，从而支持高效的集束搜索。

### 1.2.3 多级状态评估机制

现有的基于 LLM 的规划方法往往在生成后才进行验证，容易陷入“生成-失败-重试”的低效循环。TAES 引入了一个多级评估函数  $V(S)$ ，深度融合了硬逻辑剪枝与启发式引导。

#### 1.2.3.1 符号化硬约束剪枝

在此阶段，TAES 引入一组符号化规则集  $\Omega$ ，用于检测当前部分计划是否违反了任何即时可验证的硬性约束。如果检测到违约，状态价值立即置为 0，触发剪枝。

$$V_{hard}(S) = \begin{cases} 0, & \text{if } \exists c \in \Omega, \text{violated}(S, c) \\ 1, & \text{otherwise} \end{cases} \quad (1-3)$$

具体的剪枝逻辑  $\Omega$  包括：

- **依赖性违约**：在 TimeArena 任务场景中，动作  $A$  的执行严格依赖于其前置任务集合  $P_A$  的完成状态。符号检查器会实时检索当前状态的  $C_{met}$  集合，若  $P_A \not\subseteq C_{met}$ ，则判定为违约。在旅行规划中，这表现为逻辑链条的闭环，例如返程交通方式必须自洽，若自驾去就不能坐飞机回。
- **资源互斥**：在时刻  $\mathcal{T}_{now}$ ，系统会扫描资源快照  $\mathcal{R}$ 。若动作  $A$  涉及的物理资源，如 TimeArena 中的实验设备、厨房厨具，或 TravelPlanner 中的餐厅正处于占用/已光顾状态，则后续重叠该资源的动作将被判定为违约。针对可消耗资源如预算，系统通过实时的数值核算进行监控。当候选动作产生的累加成本  $cost(S)$  超过用户预设的总额时，立即进入失败状态。

- **属性约束：**基于用户对规划的显性要求，符号检查器会对候选属性进行校验。通过将大语言模型生成的灵活表达转化为结构化知识的表达，系统能够确保每一个被保留的规划分支在属性层面上是零违约的。通过结构化表示，符号检查器能够对涉及房型、饮食偏好及交通工具类型等等关键动作属性的严格对齐。例如，若用户要求“必须携带宠物”，则所有不具备宠物友好标签的酒店分支将被立即屏蔽。这种机制在处理多约束时，能够达到远超纯概率生成模型的稳定性。

符号化硬约束剪枝从机制最大限度上保证了凡是通过筛选进入下一轮的计划，在逻辑上是没有冲突的。

### 1.2.3.2 前瞻性风险评估

通过第一阶段筛选的计划虽然逻辑上没有冲突，但可能通向死胡同，例如预算在前几天耗尽，导致后续无解。TAES 引入启发式函数  $V_{soft}(S)$  来实时评估当前方案的风险系数，以此估计沿着该方案扩展的未来的成功概率，引导搜索向鲁棒性更高的方向发展。 $V_{soft}(S)$  可以根据不同的任务针对性设计，在旅行任务中， $V_{soft}(S)$  采用预算风险估算，在事件统筹任务中， $V_{soft}(S)$  采用时间效率估计。下面展示两种启发式评估的具体计算方式。

**预算风险估算** TAES 提出剩余日均可用预算指标来衡量财务健康度：

$$R_{budget} = \frac{Budget_{total} - cost(S)}{D_{max} - depth(S)} \quad (1-4)$$

若  $R_{budget}$  低于最低生存阈值  $\delta$ ，例如每日最低食宿成本，则给予极低分惩罚。这迫使智能体在早期做出节省预算的决策，而非贪婪地选择豪华选项。

**时间效率估算** 为了最小化总耗时，TAES 采用关键路径估算：

$$R_{time} = \frac{CompletedTasks(S)}{\mathcal{T}_{now}} + \alpha \cdot \mathbf{I}(\text{Parallelism}) \quad (1-5)$$

其中  $\mathbf{I}(\text{Parallelism})$  是并行度指示函数。TAES 会奖励那些不仅完成了任务，而且当前处于高度并行状态的路径，如人与烤箱同时工作，引导搜索向更高效的调度收敛。

**最终评分函数** 综合上述两阶段，最终状态评分函数定义为：

$$V(S) = V_{hard}(S) \cdot [\epsilon + (1 - \epsilon) \cdot V_{soft}(S)] \quad (1-6)$$

其中  $\epsilon$  是一个较小的正数，如  $10^{-1}$ ，确保未违约但风险高的路径优于直接违约的路径，但远劣于健康路径。这一设计使得 TAES 能够在保证零违约的前提下，自适应地寻找最优解。并且启发式评估的设计给方法的未来扩展留下了极大的空间，设计者可以根据不同的需求自定义启发式评估函数，不同的定义会引导最终得出的方案在不违反硬性约束的情况下朝着设计者希望的风格方向去发展，例如需要尽量用满预算或是尽量在伙食方面多投入预算等等。

### 1.3 性能评估

本章通过在两个具有代表性的复杂规划基准上进行广泛实验，旨在从多维度验证 TAES 框架的有效性。实验致力于回答以下四个核心研究问题：

- 相比于现有智能体方法，TAES 在多约束规划任务上的综合表现如何？
- TAES 是否会由于多轮调用大幅度增加计算开销导致实际系统不可用？
- 符号化剪枝、启发式评估与集束搜索策略分别对最终性能有多大贡献？
- 在 TAES 仍然失败的案例中，主要的错误来源是什么？

#### 1.3.1 实验设置

##### 1.3.1.1 数据集及其评估指标

本章选择了两个具有挑战性的基准进行实验：TravelPlanner 和 TimeArena，这两者都需要在显性和隐性约束下进行长程规划。下面描述这两个数据集及其评估指标。

**TravelPlanner** TravelPlanner 提供了一个复杂的现实世界规划环境，包含约 400 万个来自互联网的餐厅、航班、住宿和景点数据库条目。智能体必须生成涵盖交通、住宿、餐饮和景点的详细行程，同时遵守显性约束如预算限制，以及隐性常识约束如避免重复访问、必须将车归还至起点而非途中遗弃。该数据集包含 1,225 个精选的规划意图，训练/验证/测试集的比例为 45/180/1000。本章使用

45 个训练样本中的前 10 个样本来提取初始推理轨迹，并设定  $Shot = 5$  用于提示模版中的样本选择。由于任务计算成本高昂且耗时，以 DeepSeek-R1 直接生成一个旅行计划为例，就需要平均耗时 6 分钟以及 3 万左右的 token 数，因此评估在包含 180 个查询的验证集上进行，也方便与各种基线方法对比。查询根据约束的数量和复杂性分为简单、中等和困难三个级别。TravelPlanner 主要考察旅行计划对用户要求的满足程度以及最终计划的通过率，指标如下：

- **常识约束通过率 (Commonsense Constraint Pass Rate)**：满足常识约束的比例。为了更细致地评估，将其分为微观 (Micro) 和宏观 (Macro) 两个分数：

- **微观分数 (Micro)**：计算所有测试样本中，被满足的常识约束总数占所有常识约束总数的比例：

$$\text{Commonsense}_{\text{micro}} = \frac{\sum_{i=1}^N |C_{\text{common\_pass}}^{(i)}|}{\sum_{i=1}^N |C_{\text{common\_total}}^{(i)}|} \quad (1-7)$$

其中  $C_{\text{common\_total}}^{(i)}$  是第  $i$  个查询涉及的所有常识约束集合， $C_{\text{common\_pass}}^{(i)}$  是其中被满足的子集。

- **宏观分数 (Macro)**：计算单个计划成功率，即所有常识约束都得到满足的计划所占的比例：

$$\text{Commonsense}_{\text{macro}} = \frac{1}{N} \sum_{i=1}^N \mathbf{I}(|C_{\text{common\_pass}}^{(i)}| = |C_{\text{common\_total}}^{(i)}|) \quad (1-8)$$

- **硬约束通过率 (Hard Constraint Pass Rate)**：显性用户约束的满足比例。同样分为微观和宏观指标：

$$\text{Hard}_{\text{micro}} = \frac{\sum_{i=1}^N |C_{\text{hard\_pass}}^{(i)}|}{\sum_{i=1}^N |C_{\text{hard\_total}}^{(i)}|}, \quad \text{Hard}_{\text{macro}} = \frac{1}{N} \sum_{i=1}^N \mathbf{I}(|C_{\text{hard\_pass}}^{(i)}| = |C_{\text{hard\_total}}^{(i)}|) \quad (1-9)$$

其中  $C_{\text{hard\_total}}^{(i)}$  代表预算、房型、饮食偏好等显性硬约束的集合。

- **最终通过率 (Final Pass Rate)**：满足查询中所有硬约束和常识约束的计划

比例。这是衡量规划成功与否的最严格标准：

$$\text{Final Pass Rate} = \frac{1}{N} \sum_{i=1}^N [\mathbf{I}(p_i \in \text{Pass}_{\text{hard}}) \cdot \mathbf{I}(p_i \in \text{Pass}_{\text{common}})] \times 100\% \quad (1-10)$$

其中  $p_i$  表示针对第  $i$  个查询生成的计划。

- **模型调用总花费 (Cost)：** 尝试解决所有任务的模型调用花费（单位：美元）。

**TimeArena** TimeArena 是一个文本模拟环境，用于评估时间约束下的多任务处理能力。智能体必须完成多个任务，管理子任务依赖关系，并最小化空闲时间。数据集包含 90 个样本，涵盖家庭、烹饪和实验室领域，每个领域包含需要实现 1、2 或 3 个目标的样本。其原始数据集是为在线设置开发的，包含规划器与模拟器的交互，本章将 TimeArena 重构为静态设置，即在开始时直接提供所有有效动作及其持续时间。这使得基准测试纯粹专注于规划，而不是对工具调用的考察。训练/验证集划分为 27/63 个查询，并在各个领域和难度级别上保持多样性。实验同样使用 27 个训练样本中的 10 个样本来生成推理轨迹用于给基线方法训练。由于 TimeArena 的推理轨迹比 TravelPlanner 更长，本章将提示样本选择设定为较小的  $\text{Shot} = 2$  并在验证集上进行评估。

为了全面评估智能体执行多任务的能力，TimeArena 同时考量了时间与得分因素，并测试以下五个指标：

- **平均进度得分 (Average Progress Score, AS)：** 智能体能够达到的平均最高进度得分：

$$AS = \frac{\sum_{i \in N} P_i}{N} \quad (1-11)$$

其中  $P_i$  表示智能体在第  $i$  个任务上能达到的最大进度得分， $N$  表示所有任务的总数。

- **完成速度 (Completion Speed, CS)：** 最高得分除以达到该得分所需时间的平均值（单位：分/分钟）：

$$CS = \frac{\sum_{i \in N} P_i}{\sum_{i \in N} T_i} \quad (1-12)$$

其中  $T_i$  表示达到第  $i$  个任务的  $P_i$  所需的时间。

- **任务完成率 (Task Completion Rate, CR):** 成功完成任务的百分比 (%) :

$$CR = \frac{S}{N} \times 100\% \quad (1-13)$$

其中  $S$  表示成功完成任务的数量。值得注意的是, 在组合任务的场景下, 一个组合任务被算作一个任务。

- **平均完成时间 (Average Completion Time, CT):** 成功完成任务所需的平均时间 (单位: 分钟):

$$CT = \frac{\sum_{i \in S} T_i}{S} \quad (1-14)$$

- **模型调用总花费 (Cost):** 尝试解决所有任务的模型调用花费 (单位: 美元)。

### 1.3.1.2 使用模型与对比基线

实验使用来自两个模型家族的大语言模型和推理大推理。分别为闭源模型 GPT-4o<sup>[11]</sup>, o3-mini 和开源模型 DeepSeek-V3<sup>[12]</sup>, DeepSeek-R1<sup>[5]</sup>。实验阶段始终保持参数 temperature=0 以保证可复现性。最后针对需要使用训练集生成推理轨迹的方法, 实验使用 DeepSeek-R1 来生成推理轨迹。实验将 TAES 与两类代表性方法进行对比:

**单智能体基线:** Direct Prompting (直接调用模型端到端作答)。

**多智能体生成框架:** AutoBuild<sup>[13]</sup> (动态编排)、MAD<sup>[14]</sup> (辩论修正)、ExpeL<sup>[15]</sup> (经验学习)、PMC<sup>[9]</sup> (分层规划)、LRPLAN<sup>[10]</sup> (大语言模型和推理模型协同)。

## 1.3.2 主要结果

表1-1展示了不同模型与策略在 TravelPlanner 验证集上的性能对比。实验结果表明, TAES 框架在处理长程多约束规划任务上展现出了压倒性的优势。

首先, 在最关键的最终通过率指标 Final Pass Rate 上, 使用 DeepSeek-R1 的 TAES 达到了 60.00%, 使用 GPT-4o 的版本也达到了 53.89%。这一成绩显著优于现有的基线方法, 相比于 LRPLAN (21.67%) 和 PMC (20.56%), TAES 实现了

表 1-1 TravelPlanner 数据集上不同模型和方法的性能对比

| 方法          | 模型                 | Commonsense ↑ |              | Hard Constraints ↑ |              | Final Pass Rate ↑ | Cost ↓      |
|-------------|--------------------|---------------|--------------|--------------------|--------------|-------------------|-------------|
|             |                    | Micro         | Macro        | Micro              | Macro        |                   |             |
| Direct      | GPT-4o             | 84.93         | 29.44        | 41.67              | 22.22        | 3.89              | 7.10        |
| Direct      | o3-mini            | 78.82         | 17.22        | 54.29              | 41.11        | 8.33              | 5.99        |
| Direct      | DeepSeek-V3        | 80.83         | 19.44        | 44.76              | 23.33        | 4.44              | <b>0.55</b> |
| Direct      | DeepSeek-R1        | 77.36         | 16.11        | 60.24              | 45.56        | 11.11             | 1.97        |
| AutoBuild   | GPT-4o             | 86.81         | 35.56        | 60.24              | 36.67        | 12.78             | 33.02       |
| AutoBuild   | DeepSeek-R1        | 81.32         | 18.89        | 52.62              | 50.56        | 11.67             | 17.92       |
| MAD         | GPT-4o             | 79.44         | 7.78         | 10.00              | 6.67         | 2.78              | 44.06       |
| MAD         | DeepSeek-R1        | 75.97         | 8.33         | 11.11              | 10.71        | 6.11              | 16.18       |
| ExpeL       | GPT-4o             | 51.60         | 29.44        | 30.95              | 18.33        | 10.00             | 13.00       |
| PMC         | GPT-4o             | 84.21         | 34.44        | 82.14              | 65.00        | 17.78             | 19.72       |
| PMC         | DeepSeek-R1        | 85.14         | 35.56        | 84.52              | 66.67        | 20.56             | 5.71        |
| LRPLAN      | GPT-4o + o3-mini   | 88.61         | 37.22        | 71.19              | 45.56        | 17.78             | 12.41       |
| LRPLAN      | DS-V3 + DS-R1      | 85.90         | 30.00        | 72.14              | 60.56        | 21.67             | 3.30        |
| TAES        | GPT-4o             | 94.51         | 59.44        | 98.81              | 97.78        | 53.89             | 16.34       |
| <b>TAES</b> | <b>DeepSeek-R1</b> | <b>95.97</b>  | <b>65.56</b> | <b>99.52</b>       | <b>98.89</b> | <b>60.00</b>      | 5.18        |

约 3 倍的性能。这表明，单纯依靠多智能体协作或角色扮演难以解决复杂的长程依赖问题，而基于事件的搜索机制更为有效。

其次，TAES 在硬约束满足率 Hard Constraints 上表现出了近乎完美的鲁棒性。得益于符号化剪枝机制，TAES (DeepSeek-R1) 的硬约束微观满足率高达 99.52%，宏观满足率达 98.89%。相比之下，同样是引入了推理模型进行修正的 LRPLAN，其硬约束满足率也仅为 72.14%。这有力地验证了将显性规则从大语言模型的生成过程中剥离并交给代码逻辑处理是消除幻觉、确保低违约的关键。

最后，在成本方面，尽管搜索算法通常被认为开销巨大，但 TAES 通过高效的事件跳跃机制控制了搜索深度。并且通过分而治之将每一步的回溯控制在单步之内，与之形成对比的是直接端到端生成时，推理模型会在完整生成计划后发现不符合要求时从头思考，从而浪费大量计算量与花销。TAES (DeepSeek-R1) 的平均花费仅为 \$5.18，远低于 AutoBuild (\$17.92) 和 MAD (\$16.18)，在保证高性能的同时维持了极高的性价比。这也有力验证了 TAES 并非一味通过计算量换取性能，而是一种兼顾性能与开销的启发式算法。

表1-2展示了在 TimeArena 数据集上的实验结果。该任务侧重于在严格的时间依赖和资源独占约束下进行效率优化。

TAES 在任务完成率 CR 和平均完成时间 CT 两个核心指标上均取得了最优结果。具体而言，TAES (DeepSeek-R1) 的任务完成率达到了 92.75%，显著高于 AutoBuild (48.41%) 和 LRPLAN (68.25%)。更重要的是，TAES 生成的计划更

表 1-2 TimeArena 数据集上不同模型和方法的性能表现

| 方法          | 模型                 | CT ↓         | CS ↑        | AS ↑         | CR ↑         | Cost ↓      |
|-------------|--------------------|--------------|-------------|--------------|--------------|-------------|
| Direct      | GPT-4o             | 26.47        | 2.40        | 69.63        | 37.30        | 0.30        |
| Direct      | o3-mini            | 28.00        | 2.79        | 88.30        | 61.90        | 1.70        |
| Direct      | DeepSeek-V3        | 25.80        | 2.47        | 51.89        | 15.87        | <b>0.04</b> |
| Direct      | DeepSeek-R1        | 28.02        | 2.91        | 75.70        | 43.75        | 1.06        |
| AutoBuild   | GPT-4o             | 27.62        | 2.80        | 68.07        | 31.71        | 4.17        |
| AutoBuild   | DeepSeek-R1        | 27.66        | 3.15        | 79.39        | 48.41        | 6.45        |
| MAD         | GPT-4o             | 27.74        | 2.71        | 71.23        | 36.51        | 3.17        |
| MAD         | DeepSeek-R1        | 26.24        | 3.32        | 75.77        | 41.07        | 8.12        |
| ExpeL       | GPT-4o             | 29.42        | 2.36        | 63.68        | 26.19        | 3.04        |
| PMC         | GPT-4o             | 28.04        | 2.56        | 78.77        | 58.83        | 1.02        |
| PMC         | DeepSeek-R1        | 27.42        | 2.78        | 80.02        | 62.25        | 1.96        |
| LRPLAN      | GPT-4o + o3-mini   | 31.94        | 3.01        | 94.64        | 83.33        | 2.45        |
| LRPLAN      | DS-V3 + DS-R1      | 27.84        | 3.14        | 89.95        | 68.25        | 0.96        |
| TAES        | GPT-4o             | 23.58        | 3.99        | 97.50        | 91.50        | 1.12        |
| <b>TAES</b> | <b>DeepSeek-R1</b> | <b>23.24</b> | <b>4.11</b> | <b>98.50</b> | <b>92.75</b> | 2.12        |

加高效，平均完成时间 CT 仅为 23.24 分钟，而其他基线方法通常需要 27 分钟以上。

这一结果表明，TAES 的事件驱动时间跳跃机制能够精确地捕捉动作之间的物理依赖。基线方法如 MAD, ExpeL 往往因为大语言模型无法精确计算时间窗口而导致动作冲突或不必要的等待，而 TAES 通过前瞻性搜索，能够找到并行度更高、耗时更短的执行路径，从而实现了效率与正确性的双重提升。此外，TAES 的模型调用开销同样并不高，低于 MAD, AutoBuild, ExpeL 和 PMC，略高于 LRPLAN，处在实际使用时可以接受的水准。

### 1.3.3 消融实验

为了探究 TAES 框架中各组件的贡献，本章在 TravelPlanner 和 TimeArena 上进行了消融研究。结果分别如表1-3和表1-4所示。本章主要关注符号化硬剪枝、启发式评估以及搜索宽度的影响。

移除符号化硬剪枝（w/o Symbolic Pruning）对系统性能造成了毁灭性打击。以 DeepSeek-R1 模型为例，在 TravelPlanner 中，硬约束满足率从 99.52% 骤降至 61.90%，TimeArena 的 CR 也从 92.75% 下降至 52.25%，系统退化为普通的概率



表 1-3 TravelPlanner 上的消融实验

| 方法                        | Commonsense $\uparrow$ |       | Hard Constraints $\uparrow$ |       | Final<br>Pass<br>Rate $\uparrow$ |
|---------------------------|------------------------|-------|-----------------------------|-------|----------------------------------|
|                           | Micro                  | Macro | Micro                       | Macro |                                  |
| <i>GPT-4o</i>             |                        |       |                             |       |                                  |
| TAES ( $B = 5$ )          | 94.51                  | 59.44 | 98.81                       | 97.78 | 53.89                            |
| w/o Symbolic Pruning      | 85.97                  | 37.78 | 55.00                       | 35.56 | 23.89                            |
| w/o Heuristic Eval        | 92.99                  | 53.89 | 95.00                       | 90.00 | 42.20                            |
| Greedy Search ( $B = 1$ ) | 87.99                  | 38.89 | 96.90                       | 95.56 | 45.00                            |
| <i>DeepSeek-R1</i>        |                        |       |                             |       |                                  |
| TAES ( $B = 5$ )          | 95.97                  | 65.56 | 99.52                       | 98.89 | 60.00                            |
| w/o Symbolic Pruning      | 82.01                  | 23.89 | 61.90                       | 50.00 | 22.22                            |
| w/o Heuristic Eval        | 94.51                  | 62.22 | 99.04                       | 96.11 | 55.00                            |
| Greedy Search ( $B = 1$ ) | 87.99                  | 57.78 | 98.10                       | 97.78 | 48.89                            |

表 1-4 TimeArena 数据集上的消融实验

| 方法                               | CT $\downarrow$ | CS $\uparrow$ | AS $\uparrow$ | CR $\uparrow$ |
|----------------------------------|-----------------|---------------|---------------|---------------|
| <i>GPT-4o</i>                    |                 |               |               |               |
| <b>TAES (<math>B = 5</math>)</b> | <b>23.58</b>    | <b>3.99</b>   | <b>97.50</b>  | <b>91.50</b>  |
| w/o Symbolic Pruning             | 23.88           | 2.60          | 77.03         | 50.25         |
| w/o Heuristic Eval               | 25.20           | 3.60          | 90.10         | 81.75         |
| Greedy Search ( $B = 1$ )        | 23.68           | 3.82          | 92.05         | 82.83         |
| <i>DeepSeek-R1</i>               |                 |               |               |               |
| <b>TAES (<math>B = 5</math>)</b> | <b>23.24</b>    | <b>4.11</b>   | <b>98.50</b>  | <b>92.75</b>  |
| w/o Symbolic Pruning             | 24.10           | 3.01          | 81.39         | 52.25         |
| w/o Heuristic Eval               | 27.02           | 3.73          | 92.77         | 85.56         |
| Greedy Search ( $B = 1$ )        | 23.97           | 3.92          | 90.51         | 80.43         |

生成模型。这一结果说明即便是推理能力极强的 DeepSeek-R1，在缺乏符号约束的情况下，仍会频繁产生预算计算错误或时序幻觉。

移除启发式评估（w/o Heuristic Eval）后，虽然硬约束满足率依然维持高位，但最终通过率出现了明显下滑，同样以 DeepSeek-R1 模型为例，TravelPlanner 的 Final Pass Rate 从 60% 下降至 55%，TimeArena 的 CR 从 92.75% 下降至 85.56%。深入分析发现，失去启发式引导的智能体倾向于做出短视决策，例如在第一天就耗尽大部分预算预订豪华酒店，导致后续规划因资源枯竭而陷入死锁。这验证了前瞻性风险评估在长程规划中不可或缺。

将集束搜索 (Beam Search,  $B = 5$ ) 退化为贪心搜索 (Greedy Search,  $B = 1$ ) 进行对比。结果显示, 贪心搜索的性能在两个数据集上均有明显下降。同样以 DeepSeek-R1 模型为例, TravelPlanner 的 Final Pass Rate 60% 下降至 48.89%, TimeArena 的 CR 从 92.75% 下降至 80.43%。这说明在多约束规划问题中, 单条路径往往容易走入死胡同, 而保留 Top- $B$  个候选状态能够提供回溯和容错的空间, 从而提高找到可行解的概率。将集束宽度退化为  $B = 1$  后, 性能在两个数据集上均有下降。这表明, 在多约束耦合的复杂解空间中, 保留 Top- $B$  个候选路径能够提供关键的回溯与容错空间, 避免智能体过早陷入局部最优陷阱。

### 1.3.4 错误分析

尽管 TAES 取得了显著进展, 但仍有部分失败案例。本节对错误进行了分类统计与定性分析:

- **多约束解析与形式化失败 (占比 48%)**: 这是最主要的错误来源。TAES 的有效性依赖于将自然语言查询准确转化为形式化约束  $\Omega_{hard}$ 。由于约束解析实现是基于代码逻辑的, 而这种硬编码解析通常不具有灵活性。如果语义理解阶段未能成功识别出显性约束, 例如将“我不吃法餐”的要求错误转化为“菜系为法国菜”, 或者未能成功解析无视了该要求, 后续的符号剪枝也将一并出错导致计划的最终失败。
- **常识约束不满足 (占比 42%)**: 现有的搜索算法主要侧重于资源和时间效率, 但在衡量常识方面仍显粗糙, 但这也是一大难题。因为常识通常也具有灵活性难以一言以蔽之, 无法设计通用代码逻辑全面检查。例如, 生成的路线虽然在时间和预算上都符合, 但在空间移动上可能出现不合理的折返, 导致未能通过常识约束检查。
- **时态知识图谱环境交互失败 (占比 10%)**: 此类错误表现为动作落地失败。尽管时态知识图谱提供了上下文, 大语言模型仍然偶尔会产生参数幻觉, 如捏造不存在的航班号, 或者因过度剪枝导致搜索空间在该节点的候选动作被意外清空, 引发死锁。

### 1.3.5 案例研究

为了展示 TAES 方法在解决长程依赖和约束满足这两大核心挑战上的有效性，本节选取 TravelPlanner 中的典型困难样本进行深入剖析。本章将展示 TAES 如何通过神经生成与符号剪枝的协同，避免了基线方法中常见的逻辑陷阱。

用户查询“为 3 人规划 3 月 6 日-12 日从西雅图到旧金山的 7 天行程。总预算 \$3,000。要求：必须携带宠物，全程避免飞行，品尝法餐。”难点在于“避免飞行”迫使智能体选择自驾，耗时且额外增加住宿需求，“携带宠物”限制了廉价酒店的选择。这构成了极高的预算压力。

PMC 采用了分层规划。在 Day 1，执行者 Executor 为了满足“品尝法餐”的局部约束，预订了一家米其林餐厅人均 \$200，总计 \$600。此时并没有违反局部约束。然而，这一决策导致剩余预算急剧缩水。到了 Day 5，交付者 Deliverer 发现剩余资金已无法支付必须的“宠物友好酒店”费用，且无法回溯修改 Day 1 的决策，最终导致任务在最后一步宣告失败。

TAES 利用集束搜索和多级状态评估成功规避了这一陷阱：

#### 1. Day 1 扩展与剪枝：大语言模型生成器提出了三个候选方案：

- *Plan A*: 坐飞机 (\$900) + 普通酒店 (\$150)。触发符号剪枝，检测到违反“transport\_rules” (No Flying)，状态评分置 0，立即剔除。
- *Plan B*: 租车 (\$150) + 米其林法餐 (\$600) + 宠物酒店 (\$300)。总花 \$1050。
- *Plan C*: 租车 (\$150) + 普通法餐 (\$100) + 宠物酒店 (\$300)。总花 \$550。

#### 2. 启发式风险评估 $V_{soft}$ 介入：评估器计算剩余日均可用预算：

- 对于 *Plan B*: 剩余 \$1950 / 6 天  $\approx$  \$325/天。虽然目前未超支，但系统判定该数值相对较低，给予低分 0.3。
- 对于 *Plan C*: 剩余 \$2450 / 6 天  $\approx$  \$408/天。预算相对健康，给予高分 0.9。

#### 3. 决策结果：尽管 Plan B 在局部更诱人，品尝了米其林美食，但由于启发式评估分过低，在后续搜索过程中 Plan B 的分支被 Beam Search 筛选排序剔

除。TAES 选择了 Plan C 的后续分支继续探索。最终，智能体成功生成了满足所有约束的 7 天行程。

这个案例生动地说明了，通过将用户查询转化为搜索过程中的硬性约束与启发式评估，TAES 能够有效消除大语言模型在长程规划中的短视与时态推理中的幻觉。

## 1.4 本章小结

本章针对复杂动态环境下的多约束规划问题，提出了一种基于时间感知事件搜索（TAES）的智能体框架。核心贡献在于突破了传统线性生成方法在长程依赖与硬性约束上的瓶颈。首先，通过将时态知识图谱中的信息形式化为统一的离散事件空间，并引入基于事件的状态跳跃机制，TAES 有效克服了搜索空间随时间跨度指数级爆炸的计算难题。其次，本章创新性地设计了神经符号协同机制，利用大语言模型的生成直觉提供丰富的动作候选，同时通过符号化硬约束剪枝和启发式风险评估，从理论上保证了规划的低违约率。在 TravelPlanner 和 TimeArena 两个具有挑战性的基准数据集上的实验结果表明，TAES 不仅在硬约束满足率上达到了接近 100% 的水平，更在最终任务成功率和规划效率上显著优于现有的多智能体协作框架，这有力地验证了在涉及严格时序约束的场景中，引入结构化的搜索与验证机制是提升大模型智能体鲁棒性的关键路径。

尽管 TAES 在约束满足率上取得了突破，但在通往更通用、更人性化的智能体规划系统的道路上，仍有广阔的探索空间。本章认为仍有两方面内容值得继续完善。首先是从可行解迈向优质解的开放性评估。目前的 TAES 框架主要致力于寻找满足硬性约束如满足预算、时间要求的合法计划。然而，在现实世界的旅行或生活规划中，用户的体验往往取决于难以量化的软性指标，如“行程的松弛感”、“路线的风景美观度”或“餐饮口味的惊喜感”。未来可以引入多维度的偏好评估模型，将这些开放性的舒适度指标融入启发式评估函数中，使智能体生成的计划不仅正确，而且令人愉悦。其次是动态环境下的实时响应与在线规划，目前的实验基于封闭的沙盒环境，未来将致力于将 TAES 扩展为在线规划框架，通过引入在线感知模块，将 TAES 打造成真正能在现实世界运行的规划生成系统。

## 参考文献

- [1] GENG L, CHANG E Y. REALM-Bench: A Benchmark for Evaluating Multi-Agent Systems on Real-world, Dynamic Planning and Scheduling Tasks[J]. ArXiv, 2025.
- [2] QIANYIHU Q, TU X, CONG G, et al. Time-aware ReAct Agent for Temporal Knowledge Graph Question Answering[C]//NAACL. 2025: 6013-6024.
- [3] XIE J, ZHANG K, CHEN J, et al. TravelPlanner: A Benchmark for Real-World Planning with Language Agents[C]//ICML. 2024.
- [4] ZHANG Y, YUAN S, HU C, et al. TimeArena: Shaping Efficient Multitasking Language Agents in a Time-Aware Simulation[C]//ACL. 2024.
- [5] GUO D, YANG D, ZHANG H, et al. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning[J]. ArXiv, 2025.
- [6] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models[J]. NeurIPS, 2022: 24824-24837.
- [7] YAO S, ZHAO J, YU D, et al. ReAct: Synergizing Reasoning and Acting in Language Models[C]//ICLR. 2022.
- [8] YANG Z, RAMAN S S, SHAH A, et al. Plug in the Safety Chip: Enforcing Constraints for LLM-driven Robot Agents[C]//ICRA. 2024: 14435-14442.
- [9] ZHANG C, GOH X D, LI D, et al. Planning with Multi-Constraints via Collaborative Language Agents[C]//COLING. 2025: 10054-10082.
- [10] KARTHIKEYAN T, DEHLAN O, GUPTA M, et al. LRPLAN: A Multi-Agent Collaboration of Large Language and Reasoning Models for Planning with Implicit & Explicit Constraints[C]//EMNLP. 2025: 8280-8310.

- [11] HURST A, LERER A, GOUCHER A P, et al. GPT-4o System Card[J]. ArXiv, 2024.
- [12] LIU A, FENG B, XUE B, et al. DeepSeek-V3 Technical Report[J]. ArXiv, 2024.
- [13] HONG Z, CAO D, WANG H, et al. AutoBuild: Automatic Community Building Labeling for Last-mile Delivery[C]//CIKM. 2023: 4623-4630.
- [14] DU Y, LI S, TORRALBA A, et al. Improving Factuality and Reasoning in Language Models through Multiagent Debate[C]//ICML. 2023.
- [15] ZHAO A, HUANG D, XU Q, et al. ExpeL: LLM Agents Are Experiential Learners[C]//AAAI. 2024: 19632-19642.

## 攻读博士学位期间研究成果

论文发表情况:

1. **Jianhao Chen**, Junyang Ren, Wentao Ding, Yuzhong Qu. PaTeCon: A Pattern-Based Temporal Constraint Mining Method for Conflict Detection on Knowledge Graphs[C]//AAAI. 2023: 4166-4172. (CCF-A 类会议)
2. **Jianhao Chen**, Haoyuan Ouyang, Junyang Ren, Wentao Ding, Wei Hu, and Yuzhong Qu. Timeline-based Sentence Decomposition with In Context Learning for Temporal Fact Extraction[C]//ACL. 2024: 3415-3432. (CCF-A 类会议)
3. **Jianhao Chen**, Zishuo Xun, Bocheng Zhou, Han Qi, Hangfan Zhang, Qiaosheng Zhang, Yang Chen, Wei Hu, Yuzhong Qu, Shuyue Hu. Do We Truly Need So Many Samples? Multi-LLM Repeated Sampling Efficiently Scales Test-Time Compute[C]//AAAI. 2026. (CCF-A 类会议)
4. Wentao Ding, **Jianhao Chen**, Jinmao Li, and Yuzhong Qu. Automatic Rule Generation for Time Expression Normalization[C]//Findings of EMNLP. 2021: 3135-3144. (CCF-B 类会议 Findings)
5. Wentao Ding, **Jianhao Chen**, Jinmao Li, Yuzhong Qu. Time Expression as Update Operations: Normalizing Time Expressions Via a Distantly Supervised Neural Semantic Parser[J]. KBS, 2023: 278. (CCF-C 类期刊)
6. Yiqun Zhang, Hao Li, **Jianhao Chen**, Hangfan Zhang, Peng Ye, Lei Bai, Shuyue Hu. Beyond GPT-5: Making LLMs Cheaper and Better via Performance-Efficiency Optimized Routing[C]//DAI. 2025: 122-129. (非 CCF 会议, Best Paper Award)
7. Chenxu Wang, Hao Li, Yiqun Zhang, Linyao Chen, **Jianhao Chen**, Ping Jian, Peng Ye, Qiaosheng Zhang, Shuyue Hu. ICL-Router: In-Context Learned Model Representations for LLM Routing[C]//AAAI. 2026. (CCF-A 类会议)